

Treino, validação e teste

Aula 5.2 — a disciplina do conjunto trancado e o vazamento de dados que inventa métricas boas.

O que vamos fazer hoje

01

Objetivos

5 min

02

Recapitulação

10 min

03

Teoria

35 min

04

Quiz rápido

10 min

05

Exercício guiado

45 min

06

Erros comuns

8 min

07

Desafio de casa

5 min

08

Leitura

2 min

Ao final da aula, você consegue

01

Explicar o papel de treino, validação e teste

02

Justificar por que o teste fica trancado

03

Definir vazamento de dados com um exemplo

04

Identificar um vazamento num notebook alheio

05

Corrigir a ordem das etapas e medir de novo

06

Ler R^2 , MAE e RMSE com desconfiança saudável

Da Aula 5.1 para hoje

O que você já sabe fazer

O ciclo inteiro no Iris: carregar, separar, treinar, prever e ler a métrica.

O que muda hoje

Aparece um terceiro conjunto, a validação — e a pergunta deixa de ser qual é a métrica e passa a ser se a métrica é honesta.

03

Teoria

Um dataset, três papéis



Se você usa o teste para tomar decisões, ele deixa de ser um teste independente.

Ele passa a ser mais um conjunto de validação — e você fica sem nenhuma estimativa limpa do mundo real.

O conjunto trancado



TESTE

20% das linhas, separadas na primeira célula



Não olhar

nem para explorar, nem para conferir a distribuição



Não ajustar

nenhuma transformação aprende algo com ele



Não escolher modelo

quem decide é a validação



Abrir apenas no final

uma vez, com o modelo já escolhido

Vazamento de dados

**Qualquer informação do teste que chega ao treino
— direta ou por estatística.**

Como ele se apresenta

A métrica sobe e o modelo parece pronto. Em produção o acerto volta ao nível de antes.

Por que passa batido

Nenhum erro é levantado. O código roda e o número errado vai para o relatório.


A mesma receita, duas ordens

❌ Vazamento



A média e o desvio foram calculados com o teste dentro.

✅ Sem vazamento



O escalonamento aprende só com o treino; o teste passa por ele já pronto.

Toda transformação que **aprende algo dos dados deve aprender somente com o treino.**

StandardScaler

SimpleImputer

OneHotEncoder

seleção de features


Todas essas guardam números tirados do dado que veem. Se elas virem o teste, o teste já vazou.

Cinco formas de vazar

01	Pré-processamento antes do split	a estatística da transformação já viu o teste
02	Linhas duplicadas	a mesma amostra está nos dois conjuntos
03	Feature com informação futura	a coluna só existe depois do fato que se quer prever
04	Dados temporais misturados	treinar com amanhã para prever ontem
05	Mesmo grupo nos dois lados	várias linhas do mesmo cliente, paciente ou sensor

E quando sobra pouco dado?

A validação vira um giro: cada parte do treino é validação uma vez. O teste continua trancado.



azul = validação do fold · cinza = treino do fold

04

Quiz rápido

Qual conjunto deve permanecer intocado até a avaliação final?

A Treino

B Validação

C Teste

D Todos

Resposta: C · Teste

A Treino

B Validação

C Teste

D Todos

O treino é onde o modelo aprende. A validação pode ser consultada quantas vezes quiser. O teste, uma vez só.

Por que escalonar antes do split causa vazamento?

- A Porque o escalonamento fica mais lento com o dataset inteiro
- B Porque a média e o desvio usados são calculados com as linhas do teste
- C Porque o teste precisa ficar em outra escala que o treino
- D Não causa vazamento: escalonar é uma operação neutra

Resposta: B

- A Porque o escalonamento fica mais lento com o dataset inteiro
- B Porque a média e o desvio usados são calculados com as linhas do teste**
- C Porque o teste precisa ficar em outra escala que o treino
- D Não causa vazamento: escalonar é uma operação neutra

Esses dois números são informação sobre o teste. O modelo treina num dado que já foi ajustado com eles.

Seu modelo deu $R^2 = 0,99$ no teste. O que você verifica antes de comemorar?

- A Nada: R^2 alto é exatamente o objetivo
- B Aumento o `test_size` e rodo de novo
- C Se alguma feature contém o alvo e se algo foi transformado antes do split
- D Troco de modelo para confirmar o resultado

Resposta: C

- A Nada: R^2 alto é exatamente o objetivo
- B Aumento o `test_size` e rodo de novo
- C Se alguma feature contém o alvo e se algo foi transformado antes do split**
- D Troco de modelo para confirmar o resultado

Uma métrica quase perfeita é hipótese de vazamento, não prova de talento. Duplicatas entram na mesma checagem.

05

Exercício guiado

Uma investigação em cinco etapas

California Housing · prever o valor mediano das casas · R^2 , MAE e RMSE.

01

Um modelo
aparentemente
excelente

02

Investigação

03

Descoberta do
vazamento

04

Correção

05

Comparação
honesta

Um modelo aparentemente excelente

A célula

```
modelo.fit(X_tr, y_tr)
r2_score(y_te, modelo.predict(X_te))
```

O notebook chegou pronto. O split existe, a semente está fixa, o código roda sem aviso.

O resultado

0,99

R^2 no conjunto de teste.

Pergunta para a turma: prever preço de imóvel com 99% de variância explicada é plausível?

Investigação: quatro perguntas

Antes de mexer no modelo, auditar o caminho do dado.

01	Alguma transformação rodou antes do split?	olhar a ordem das células
02	Existem linhas duplicadas?	<code>df.duplicated().sum()</code>
03	Alguma feature é quase igual ao alvo?	correlação de cada coluna com y
04	Alguma coluna só existe depois do fato?	ler o dicionário de dados

Descoberta: a coluna culpada

Correlação com o alvo

MedInc	0,688
AveRooms	0,152
HouseAge	0,106
valor_estimado	0,998

O que é essa coluna

Uma estimativa de valor calculada a partir do próprio preço que queremos prever. Ela não existiria antes da venda.

O modelo não aprendeu o mercado imobiliário. Aprendeu a copiar uma coluna.

Correlação quase perfeita com o alvo é suspeita, não sorte.

Correção: duas mudanças

01 · Tirar a coluna vazada

Ela não estaria disponível no momento da previsão real. Fora do X.

02 · Escalonar depois do split

O escalonamento aprende só com o treino.

A célula corrigida

```
X_tr, X_te, y_tr, y_te = train_test_split(X, y, random_state=42)
modelo = make_pipeline(StandardScaler(), Ridge()).fit(X_tr, y_tr)
```

O `make_pipeline` aqui é só uma garantia mecânica de que a ordem não se inverte. Como ele funciona por dentro é assunto da Aula 5.3.

Comparação honesta

Mesmo dataset, mesmo modelo, mesma semente. Só a ordem das etapas mudou.

	✗ COM VAZAMENTO	✓ CORRETO
R ²	0,991	0,576
MAE	0,04	0,53
RMSE	0,11	0,75

Valores em unidades de 100 mil dólares — um MAE de 0,53 é um erro médio de 53 mil.

Uma métrica maior nem sempre significa um modelo melhor.

A primeira pergunta é: a avaliação é honesta?

Erros que produzem métricas falsas

✗ Pré-processar antes do split

POR QUE ACONTECE

Parece mais organizado limpar tudo de uma vez, na primeira célula.

COMO EVITAR

O split é a primeira linha depois de carregar.

✗ Ignorar duplicatas

POR QUE ACONTECE

Exportações repetidas e junções malfeitas duplicam linhas sem avisar.

COMO EVITAR

Contar duplicatas antes de separar, não depois da métrica.

✗ Usar informação futura

POR QUE ACONTECE

A tabela do banco tem colunas preenchidas depois do evento.

COMO EVITAR

Perguntar de cada coluna: eu teria isso no momento da previsão?

Erros na hora de separar e decidir

✗ Embaralhar dado temporal

POR QUE ACONTECE

O `train_test_split` sorteia por padrão, e ninguém olha a coluna de data.

COMO EVITAR

Com tempo no dado, treino é passado e teste é futuro.

✗ Separar grupos relacionados

POR QUE ACONTECE

Várias linhas do mesmo cliente, paciente ou sensor caem dos dois lados.

COMO EVITAR

O grupo inteiro fica de um lado só do split.

✗ Escolher o modelo pelo teste

POR QUE ACONTECE

É tentador rodar o teste a cada tentativa e ficar com a melhor.

COMO EVITAR

Decidir na validação; abrir o teste uma vez, no fim.

Desafio de casa

Entregue duas versões

- 01 uma contendo propositalmente um vazamento
- 02 outra corrigida, com a mesma semente

Dataset livre: California Housing, load_diabetes ou um dado seu.

Explique, em texto

- onde ocorreu o vazamento
- por que ele aconteceu
- como foi corrigido
- como R^2 , MAE e RMSE mudaram

CRITÉRIO DE ACEITE

Você aponta exatamente a linha onde o vazamento ocorreu e justifica a correção.

Leitura

-
- | | | |
|----|--|---|
| 01 | Common pitfalls: data leakage | scikit-learn.org · common_pitfalls |
| 02 | <code>train_test_split</code> | scikit-learn.org · model_selection |
| 03 | Cross-validation: evaluating estimator performance | scikit-learn.org · cross_validation |
| 04 | Métricas de regressão: R^2 , MAE e RMSE | scikit-learn.org · metrics |
-

Aula 5.3

Como colocar essas regras dentro de um Pipeline?

Imputação, codificação e escalonamento num objeto só, com caminhos separados para colunas numéricas e categóricas — no Titanic.