

Treino, validação e teste

Aula 5.2 — a disciplina do conjunto trancado e o vazamento de dados que inventa métricas boas.

O que vamos fazer hoje

01	Objetivos 5 min	02	Recapitulação 10 min	03	Teoria 35 min	04	Quiz rápido 10 min
05	Exercício guiado 45 min	06	Erros comuns 8 min	07	Desafio de casa 5 min	08	Leitura 2 min

Ao final da aula, você consegue

01

Explicar o papel de treino, validação e teste

02

Justificar por que o teste fica trancado

03

Definir vazamento de dados com um exemplo

04

Identificar um vazamento num notebook alheio

05

Corrigir a ordem das etapas e medir de novo

06

Ler R^2 , MAE e RMSE com desconfiança saudável

Da Aula 5.1 para hoje

O que você já sabe fazer

O ciclo inteiro no Iris: carregar, separar, treinar, prever e ler a métrica.


O que muda hoje

Aparece um terceiro conjunto, a validação — e a pergunta deixa de ser qual é a métrica e passa a ser se a métrica é honesta.

03

Teoria

Um dataset, três papéis



Se você usa o teste para tomar decisões, ele deixa de ser um teste independente.

Ele passa a ser mais um conjunto de validação — e você fica sem nenhuma estimativa limpa do mundo real.

O conjunto trancado



TESTE

20% das linhas, separadas na primeira célula



Não olhar

nem para explorar, nem para conferir a distribuição



Não ajustar

nenhuma transformação aprende algo com ele



Não escolher modelo

quem decide é a validação



Abrir apenas no final

uma vez, com o modelo já escolhido

Vazamento de dados

Qualquer informação do teste que chega ao treino — direta ou por estatística.

Como ele se apresenta

A métrica sobe e o modelo parece pronto. Em produção o acerto volta ao nível de antes.

Por que passa batido

Nenhum erro é levantado. O código roda e o número errado vai para o relatório.


A mesma receita, duas ordens

✗ Vazamento



A média e o desvio foram calculados com o teste dentro.

✓ Sem vazamento



O escalonamento aprende só com o treino; o teste passa por ele já pronto.

Toda transformação que **aprende algo** dos dados deve **aprender somente com o treino.**

StandardScaler

SimpleImputer

OneHotEncoder

seleção de features

Todas essas guardam números tirados do dado que veem. Se elas virem o teste, o teste já vazou.

Cinco formas de vazar

- | | | |
|----|---|--|
| 01 | Pré-processamento antes do split | a estatística da transformação já viu o teste |
| 02 | Linhas duplicadas | a mesma amostra está nos dois conjuntos |
| 03 | Feature com informação futura | a coluna só existe depois do fato que se quer prever |
| 04 | Dados temporais misturados | treinar com amanhã para prever ontem |
| 05 | Mesmo grupo nos dois lados | várias linhas do mesmo cliente, paciente ou sensor |

E quando sobra pouco dado?

A validação vira um giro: cada parte do treino é validação uma vez. O teste continua trancado.



azul = validação do fold · cinza = treino do fold

04

Quiz rápido

Qual conjunto deve permanecer intocado até a avaliação final?

A Treino

B Validação

C Teste

D Todos

Resposta: C · Teste

A Treino

B Validação

C Teste

D Todos

O treino é onde o modelo aprende. A validação pode ser consultada quantas vezes quiser. O teste, uma vez só.

Por que escalonar antes do split causa vazamento?

- A** Porque o escalonamento fica mais lento com o dataset inteiro
- B** Porque a média e o desvio usados são calculados com as linhas do teste
- C** Porque o teste precisa ficar em outra escala que o treino
- D** Não causa vazamento: escalonar é uma operação neutra

Resposta: B

- A Porque o escalonamento fica mais lento com o dataset inteiro
- B Porque a média e o desvio usados são calculados com as linhas do teste**
- C Porque o teste precisa ficar em outra escala que o treino
- D Não causa vazamento: escalonar é uma operação neutra

Esses dois números são informação sobre o teste. O modelo treina num dado que já foi ajustado com eles.

Seu modelo deu $R^2 = 0,99$ no teste. O que você verifica antes de comemorar?

- A** Nada: R^2 alto é exatamente o objetivo
- B** Aumento o test_size e rodo de novo
- C** Se alguma feature contém o alvo e se algo foi transformado antes do split
- D** Troco de modelo para confirmar o resultado

Resposta: C

- A Nada: R^2 alto é exatamente o objetivo
- B Aumento o test_size e rodo de novo
- C Se alguma feature contém o alvo e se algo foi transformado antes do split
- D Troco de modelo para confirmar o resultado

Uma métrica quase perfeita é hipótese de vazamento, não prova de talento. Duplicatas entram na mesma checagem.

05

Exercício guiado

Uma investigação em cinco etapas

California Housing · prever o valor mediano das casas · R^2 , MAE e RMSE.

01	Um modelo aparentemente excelente	02	Investigação	03	Descoberta do vazamento	04	Correção	05	Comparação honesta
----	-----------------------------------	----	--------------	----	-------------------------	----	----------	----	--------------------

Um modelo aparentemente excelente

A célula

```
modelo.fit(X_tr, y_tr)
r2_score(y_te, modelo.predict(X_te))
```

O notebook chegou pronto. O split existe, a semente está fixa, o código roda sem aviso.

O resultado

0,99

R^2 no conjunto de teste.

Pergunta para a turma: prever preço de imóvel com 99% de variância explicada é plausível?

Investigação: quatro perguntas

Antes de mexer no modelo, auditar o caminho do dado.

01 Alguma transformação rodou antes do split?

olhar a ordem das células

02 Existem linhas duplicadas?

`df.duplicated().sum()`

03 Alguma feature é quase igual ao alvo?

correlação de cada coluna com y

04 Alguma coluna só existe depois do fato?

ler o dicionário de dados

Descoberta: a coluna culpada

Correlação com o alvo	
MedInc	0,688
AveRooms	0,152
HouseAge	0,106
valor_estimado	0,998

O que é essa coluna

Uma estimativa de valor calculada a partir do próprio preço que queremos prever. Ela não existiria antes da venda.

O modelo não aprendeu o mercado imobiliário. Aprendeu a copiar uma coluna.

Correlação quase perfeita com o alvo é suspeita, não sorte.

Correção: duas mudanças

01 · Tirar a coluna vazada

Ela não estaria disponível no momento da previsão real. Fora do X.

02 · Escalonar depois do split

O escalonamento aprende só com o treino.

A célula corrigida

```
X_tr, X_te, y_tr, y_te = train_test_split(X, y, random_state=42)
modelo = make_pipeline(StandardScaler(), Ridge()).fit(X_tr, y_tr)
```

O `make_pipeline` aqui é só uma garantia mecânica de que a ordem não se inverte. Como ele funciona por dentro é assunto da Aula 5.3.

Comparação honesta

Mesmo dataset, mesmo modelo, mesma semente. Só a ordem das etapas mudou.

✗ COM VAZAMENTO **✓ CORRETO**

R ²	0,991	0,576
MAE	0,04	0,53
RMSE	0,11	0,75

Valores em unidades de 100 mil dólares — um MAE de 0,53 é um erro médio de 53 mil.

Uma métrica maior nem sempre significa um modelo melhor.

A primeira pergunta é: a avaliação é honesta?

Erros que produzem métricas falsas

❌ Pré-processar antes do split

POR QUE ACONTECE

Parece mais organizado limpar tudo de uma vez, na primeira célula.

COMO EVITAR

O split é a primeira linha depois de carregar.

❌ Ignorar duplicatas

POR QUE ACONTECE

Exportações repetidas e junções malfeitas duplicam linhas sem avisar.

COMO EVITAR

Contar duplicatas antes de separar, não depois da métrica.

❌ Usar informação futura

POR QUE ACONTECE

A tabela do banco tem colunas preenchidas depois do evento.

COMO EVITAR

Perguntar de cada coluna: eu teria isso no momento da previsão?

Erros na hora de separar e decidir

✗ Embaralhar dado temporal

POR QUE ACONTECE

O `train_test_split` sorteia por padrão, e ninguém olha a coluna de data.

COMO EVITAR

Com tempo no dado, treino é passado e teste é futuro.

✗ Separar grupos relacionados

POR QUE ACONTECE

Várias linhas do mesmo cliente, paciente ou sensor caem dos dois lados.

COMO EVITAR

O grupo inteiro fica de um lado só do split.

✗ Escolher o modelo pelo teste

POR QUE ACONTECE

É tentador rodar o teste a cada tentativa e ficar com a melhor.

COMO EVITAR

Decidir na validação; abrir o teste uma vez, no fim.

Desafio de casa

Entregue duas versões

- 01 uma contendo propositalmente um vazamento
 - 02 outra corrigida, com a mesma semente
- Dataset livre: California Housing, load_diabetes ou um dado seu.

Explique, em texto

- onde ocorreu o vazamento
- por que ele aconteceu
- como foi corrigido
- como R^2 , MAE e RMSE mudaram

CRITÉRIO DE ACEITE

Você aponta exatamente a linha onde o vazamento ocorreu e justifica a correção.

Leitura

01 Common pitfalls: data leakage

[scikit-learn.org · common_pitfalls](https://scikit-learn.org/1.0/developers/faq.html#common-pitfalls)

02 train_test_split

[scikit-learn.org · model_selection](https://scikit-learn.org/1.0/developers/faq.html#model-selection)

03 Cross-validation: evaluating estimator performance

[scikit-learn.org · cross_validation](https://scikit-learn.org/1.0/developers/faq.html#cross-validation)

04 Métricas de regressão: R², MAE e RMSE

[scikit-learn.org · metrics](https://scikit-learn.org/1.0/developers/faq.html#metrics)

Aula 5.3

Como colocar essas regras dentro de um Pipeline?

Imputação, codificação e escalonamento num objeto só, com caminhos separados para colunas numéricas e categóricas — no Titanic.