Árvore de Decisão

Resumo da Aula 6.9

Objetivo: aprender a classificar exemplos por uma sequência de perguntas. A árvore aprende quais perguntas fazer a partir dos dados de treino.

1. Onde isso entra no machine learning?

Nesta aula, usamos **aprendizado supervisionado para classificação**. As características dos clientes formam **X**, e a resposta conhecida, como comprou (1) ou não comprou (0), forma **y**.

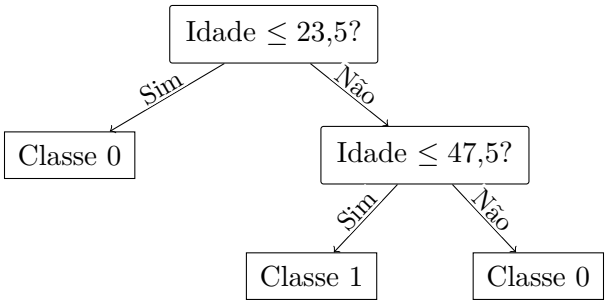
Na regressão linear, o modelo aprende os pesos de uma fórmula. **Na árvore, ele aprende perguntas e caminhos** para prever a classe de exemplos novos.

2. As partes de uma árvore

- **Raiz:** primeira pergunta.
- **Nó interno:** uma pergunta sobre uma característica.
- **Ramificação:** caminho escolhido pela resposta.
- **Folha:** resultado final, sem novas perguntas.
- **Profundidade:** número de ligações da raiz até um nó.

3. Como a árvore toma uma decisão?

Neste exemplo dos slides, as perguntas usam apenas a idade:



Um cliente de **30 anos** responde "não" à primeira pergunta e "sim" à segunda. Chega à folha **classe 1**. No treino, a árvore constrói as regras; na previsão, apenas percorre as regras já aprendidas.

4. Como escolher uma boa pergunta?

A árvore procura divisões que deixem os grupos **menos misturados entre as classes**. Para medir essa mistura, usa a **impureza de Gini**:

$$Gini = 1 - \sum_i p_i^2.$$

O valor p_i é a proporção de exemplos da classe i dentro do grupo.

- **Gini = 0:** todos pertencem à mesma classe; o grupo é puro.
- **Gini = 0,5:** metade de cada classe; mistura máxima no caso binário.
- **Entre 0 e 0,5:** mistura parcial, no caso binário.

Considere os seis clientes usados no exemplo dos slides:

Idade	**Comprou?**
18	0
22	0
25	1
40	1
45	1
50	0

Como temos três exemplos de cada classe, a impureza inicial é:

$$Gini = 1 - (0{,}5^2 + 0{,}5^2) = 0{,}5.$$

5. Comparar cortes pelo Gini ponderado e pelo ganho

O treinamento testa cortes nas características. Para números, os candidatos podem ser pontos médios entre valores distintos consecutivos: entre 22 e 25, por exemplo, o corte é 23,5.

A pergunta **"idade $\leq$ 23,5?"** produz dois grupos:

- **Esquerda:** $[0, 0]$; dois clientes e Gini 0.
- **Direita:** $[1, 1, 1, 0]$; quatro clientes e Gini 0,375.

Consideramos os tamanhos dos grupos, usando uma média ponderada:

$$Gini_{\text{divisão}} = \frac{n_{\text{esq}}}{n} Gini_{\text{esq}} + \frac{n_{\text{dir}}}{n} Gini_{\text{dir}} = \frac{2}{6} \cdot 0 + \frac{4}{6} \cdot 0{,}375 = 0{,}25.$$

A redução da impureza é chamada de **ganho**:

$$Ganho = Gini_{\text{pai}} - Gini_{\text{divisão}} = 0{,}5 - 0{,}25 = 0{,}25.$$

Em cada nó, escolhemos o corte com **menor Gini ponderado**, equivalente ao maior ganho. Com várias características, comparamos os candidatos de todas as colunas de X.

6. Por que usar recursividade?

Após uma divisão, cada grupo pode precisar de novas perguntas. A construção repete o mesmo processo em grupos menores:

- Verificar se precisa parar.
- Procurar o melhor corte.
- Dividir os exemplos em dois grupos.
- Repetir o processo em cada lado.

Isso é **recursividade**: uma função chama a si mesma para resolver versões menores do problema. Quando a construção para, cria uma **folha com a classe majoritária** daquele grupo.

7. Quando a árvore deve parar?

- **Grupo puro:** todos já pertencem à mesma classe.
- **`max_depth`:** a profundidade máxima foi atingida.
- **`min_samples_split`:** há poucos exemplos para tentar dividir.
- **`min_samples_leaf`:** o corte deixaria poucos exemplos em algum filho.
- **Nenhum corte válido com ganho:** a divisão não melhora a separação ou não respeita os limites.

8. Overfitting e poda

Uma árvore muito detalhada pode acertar todos os exemplos de treino e funcionar pior em dados novos. Isso é **overfitting**: melhorar o ajuste ao treino não garante melhor generalização.

Podar é simplificar a árvore para controlar sua complexidade:

- **Pré-poda:** impede certas divisões durante o crescimento, usando limites como a profundidade máxima.
- **Pós-poda:** simplifica uma árvore já construída, substituindo partes por folhas.

A poda pode ajudar, mas podar demais também pode prejudicar o modelo. A escolha usa **validação**; o teste fica para a avaliação final.

9. Como saber se a árvore aprendeu algo útil?

Usamos as regras aprendidas para prever classes de exemplos separados do treino e comparamos com suas respostas conhecidas. A **acurácia** é a proporção de previsões corretas; a **matriz de confusão** mostra quais classes foram acertadas e confundidas.

Fonte: Aula 6.9 - Árvore de Decisão do Zero, especialmente slides 5 a 60. Resumo adaptado para estudo.