K-Means

Resumo da Aula 6.10

Objetivo: encontrar grupos de exemplos semelhantes sem receber as respostas corretas durante o treinamento. O K-Means organiza os dados por proximidade e representa cada grupo por um centro.

1. Onde isso entra no machine learning?

É **aprendizado não supervisionado**. Recebemos características **X**, como frequência de compras e gasto médio, sem uma resposta **y** indicando o grupo correto de cada cliente. Procurar esses grupos é fazer **agrupamento**, ou *clustering*.

O **KNN** consulta K vizinhos conhecidos para prever uma resposta. No **K-Means**, K significa a quantidade de grupos que queremos formar.

2. K, cluster e centroide

- **K:** número de grupos, escolhido antes do treinamento.
- **Cluster:** um grupo de exemplos.
- **Centroide:** posição média dos exemplos do grupo; calculamos a média separadamente em cada característica.

3. Exemplo: agrupar clientes com K = 2

Cliente	Compras por mês	Gasto médio
Ana	2	R$ 30
Bia	3	R$ 35
Carlos	15	R$ 200
Diego	16	R$ 210

Uma inicialização simples sorteia duas amostras como centros. Se começarmos nas posições de Ana e Carlos, Ana/Bia ficam mais próximas do primeiro centro e Carlos/Diego, do segundo.

Atualizamos cada centro com a média do seu grupo:

- **Ana/Bia:** $(2 + 3)/2 = 2{,}5$ compras e $(30 + 35)/2 =$ R$ 32,50.
- **Carlos/Diego:** 15,5 compras e gasto médio de R$ 205.

O centroide não precisa ser um cliente real: é uma referência que resume o grupo. As médias estão nas unidades originais; o cuidado com as escalas aparece na seção 8.

Fonte: Aula 6.10 - K-Means do Zero. Exemplo de clientes adaptado.

4. O ciclo: atribuir e atualizar

1. Escolher K e inicializar os centros.
2. Calcular as distâncias dos pontos aos centros.
3. Atribuir cada ponto ao centro mais próximo.
4. Recalcular cada centro pela média do seu grupo.
5. Repetir as atribuições e atualizações até o critério de parada.

A proximidade é medida pela **distância euclidiana**. O algoritmo pode comparar as distâncias ao quadrado: o centro mais próximo continua sendo o mesmo.

Se os centros iniciais forem Ana e Bia: Carlos e Diego ficam inicialmente com Bia, o centro disponível mais próximo deles. Esse segundo centro se move para a média de Bia/Carlos/Diego: aproximadamente **11,33 compras e R$ 148,33**.

Na próxima atribuição, Bia fica mais próxima do centro da Ana. Os grupos passam a ser Ana/Bia e Carlos/Diego, e suas médias são recalculadas. **Os centros se movem; não ficam presos às pessoas sorteadas.** Neste exemplo, o ciclo corrige a divisão inicial; em outros dados, isso não é garantido.

5. Quando parar e por que controlar o sorteio?

Convergência ocorre quando o processo estabiliza, por exemplo, quando os centros praticamente param de mudar.

- `tol:` tolerância para considerar pequeno o movimento dos centros.
- `max_iter:` limite de repetições; atingir esse limite não garante convergência.
- `random_state:` semente que permite reproduzir o sorteio com os mesmos dados e configurações. O número não indica a quantidade de grupos.

Pontos de partida diferentes podem produzir resultados diferentes. Podemos fazer **várias inicializações** e guardar a de menor inércia. Isso aumenta a chance de uma solução melhor, sem garantir a melhor solução possível.

6. Inércia: medir a compactação dos grupos

A inércia soma as **distâncias ao quadrado** de cada ponto ao centro do seu grupo:

$$J = \sum_i d_i^2, \qquad d_i = \text{distância do ponto } i \text{ ao seu centro.}$$

Pontos próximos dos seus centros produzem inércia menor. Para **os mesmos dados, na mesma escala e com o mesmo K**, preferimos a menor inércia. Ela não é porcentagem de acertos nem garante que os grupos tenham uma interpretação útil.

7. Escolher K pelo método do cotovelo

Testamos diferentes valores de K e observamos a inércia. Em um dataset maior, imagine estes resultados hipotéticos:

K	Inércia
1	300
2	147
3	22
4	17
5	12

Até K = 3, a queda é grande; depois, a melhora fica pequena. **K = 3 é um bom candidato pelo cotovelo**. Procuramos onde a redução perde força, não apenas a menor inércia. O cotovelo pode não ser claro; a escolha também depende do sentido dos grupos no problema.

8. Escalas diferentes afetam as distâncias

Entre Ana e Bia, a diferença de gasto é 5 reais. Se registrarmos em centavos, vira 500, enquanto a diferença de compras continua sendo 1. O comportamento não mudou, mas uma característica pode dominar a distância só por sua unidade.

A **padronização** coloca as características em escalas comparáveis. Agrupamos nessa representação e podemos interpretar os centros novamente em compras por mês e reais.

9. Tratar grupos vazios

Se nenhum ponto escolher um centro, seu grupo fica vazio e não podemos calcular sua média normalmente. Isso pode gerar **NaN**, um resultado numérico indefinido.

Uma estratégia da aula é reposicionar o centro vazio na posição de um ponto que esteja **longe do centro do seu grupo atual**. Depois recalculamos as distâncias e deixamos os pontos escolherem seus grupos novamente.

10. Interpretar os grupos e usar o modelo

- **Grupo 0, 1 ou 2:** são identificadores, não categorias ordenadas. Os números podem se inverter entre execuções, mantendo o mesmo agrupamento.
- **Interpretação:** observamos as características dos grupos e damos significado a eles, como clientes frequentes ou que gastam menos.
- `fit(X)`: aprende os centros sem receber respostas corretas.
- `predict(X_novo)`: associa novos pontos ao centro aprendido mais próximo, sem recalcular os centros.

Limitações: K-Means favorece grupos compactos, pode separar mal formatos como anéis e sofre influência de valores extremos.