# PCA

Resumo da Aula 6.11

**Objetivo:** representar os dados com menos características, preservando o máximo possível de sua variância. O PCA cria novas características combinando as originais e permite reduzir a dimensionalidade.

### 1. Onde isso entra no machine learning?

PCA significa **Análise de Componentes Principais**. É uma técnica **não supervisionada**: aprende a transformação a partir de **X**, sem consultar respostas **y**. Pode preparar dados para outro algoritmo, como K-Means ou um classificador, e facilitar a visualização.

Cada coluna é uma característica ou **dimensão**. Reduzir de quatro dimensões para duas mantém as mesmas amostras, agora representadas por dois números. Os componentes são combinações das colunas originais.

### 2. Exemplo: duas notas que variam juntas

| **Aluno** | **Matemática** | **Física** |
|---|---|---|
| Ana | 4 | 5 |
| Bia | 7 | 8 |
| Carlos | 9 | 10 |

As duas notas acompanham uma à outra. Neste exemplo, física é sempre matemática mais um; parte da informação das duas colunas se repete.

### 3. Centralizar e calcular a covariância

Centralizar é **subtrair de cada valor a média de sua coluna**. As médias são aproximadamente 6,67 e 7,67. Ana passa a ter $(-2{,}67, -2{,}67)$: ficou abaixo da média nas duas matérias. Cada coluna centralizada tem média zero.

A **variância** mede o espalhamento de uma característica. A **covariância** mede como duas características variam juntas. Aqui ela é positiva: as notas acompanham uma à outra.

$$X_c = X - \mu, \qquad C = \frac{X_c^T X_c}{n-1}$$

$\mu$ reúne as médias, $n$ é a quantidade de amostras e $T$ indica a transposta. A diagonal de $C$ contém variâncias; as outras posições contêm covariâncias. No exemplo, os quatro valores de $C$ são aproximadamente 6,33.

*Fonte: Aula 6.11 - PCA por Álgebra Linear. Exemplo de notas adaptado.*

### 4. Autovetores, autovalores e componentes

Os **autovetores** da covariância indicam direções; seus **autovalores** medem a variância dos dados projetados nessas direções. Usamos vetores de comprimento 1 e ordenamos pelos autovalores, do maior para o menor.

- **PC1:** direção de maior variância.
- **PC2:** direção perpendicular à primeira, com a maior variância restante. Os demais seguem essa regra.

No exemplo das notas, PC1 acompanha as duas notas aumentando juntas. PC2 mede a diferença entre seus desvios; sua variância é zero, pois as colunas centralizadas são idênticas.

### 5. Projetar: transformar duas colunas em uma

Os pesos do PC1 são aproximadamente 0,707 para cada matéria:

$$PC1 \approx 0{,}707\, M_c + 0{,}707\, F_c$$

$M_c$ e $F_c$ são as notas centralizadas. Os resultados aproximados são **Ana:** $-3{,}77$**; Bia:** $0{,}47$**; Carlos:** 3,30. Cada aluno passa a ter uma coordenada na nova direção. Esses números podem entrar em outro algoritmo de ML.

Em forma matricial, guardamos os $k$ autovetores escolhidos nas colunas de $W$ e calculamos $Z = X_c W$. Se $X$ tem formato $n \times p$, $W$ tem $p \times k$ e a representação reduzida $Z$ tem $n \times k$.

### 6. Escolher quantos componentes manter

A **proporção de variância explicada** de um componente é seu autovalor dividido pela soma de todos os autovalores:

$$EVR_j = \frac{\lambda_j}{\sum_i \lambda_i}$$

Se PC1 explica 70%, PC2 explica 25% e PC3 explica 5%, manter os dois primeiros preserva 95%. Podemos escolher o menor $k$ que atinge um percentual desejado. **95% é uma escolha de compromisso**, não uma regra universal nem uma porcentagem de acertos do modelo.

### 7. Reconstruir e medir a perda

A reconstrução aproxima as características originais usando os componentes mantidos:

$$\widehat{X} = ZW^T + \mu$$

Nas notas, um componente recupera os valores originais porque o descartado tinha variância zero. Em geral, descartar componentes com variância positiva perde informação. O **erro quadrático médio (MSE)** mede a média das diferenças ao quadrado entre os valores originais e reconstruídos.

### 8. Centralização e padronização

Subtrair a média muda o centro dos dados; **padronizar também ajusta a escala**:

$$x_{\text{pad}} = \frac{x - \mu}{s}, \qquad s = \text{desvio padrão da característica.}$$

Compras por mês e gasto em reais têm escalas diferentes. Como o PCA procura variância, uma coluna pode dominar só pela unidade numérica. Quando queremos escalas comparáveis, padronizamos antes do PCA. A padronização já inclui a centralização.

Essa escolha depende do problema: **padronizar muda as direções e a variância explicada**. No guiado com Iris, usamos as medidas originais em centímetros, apenas centralizadas, como nos slides.

### 9. SVD: outro caminho para calcular o PCA

A **decomposição em valores singulares (SVD)** trabalha diretamente com os dados centralizados:

$$X_c = U\Sigma V^T$$

As colunas de $V$ fornecem as direções principais. Os valores singulares $\sigma_j$, na diagonal de $\Sigma$, permitem obter os autovalores: $\lambda_j = \sigma_j^2/(n-1)$.

Assim, podemos calcular o mesmo PCA sem formar a matriz de covariância. A SVD costuma oferecer maior estabilidade numérica. **O sinal de um componente pode se inverter** entre implementações: ele continua no mesmo eixo, com a mesma variância e reconstrução.

### 10. Cuidados ao usar em um modelo

- **Treino e teste:** separe primeiro. Aprenda médias, escalas e componentes apenas no treino; aplique a mesma transformação ao teste.
- **Relevância:** maior variância não garante maior utilidade para prever uma resposta. Avalie o modelo depois da redução.
- **Limite:** PCA é uma transformação linear; relações mais complexas podem exigir outros métodos.
- **Código:** `fit` aprende a transformação; `transform` projeta novos dados usando o que foi aprendido.

### 11. O exemplo prático da aula: Iris

O dataset tem **150 flores e quatro características**. Ao manter **dois componentes**, representamos cada flor por dois números e conseguimos desenhá-la em um gráfico. Com as medidas apenas centralizadas, os dois componentes preservam aproximadamente **97,77% da variância**.

As espécies são usadas para colorir o gráfico. O PCA aprende os componentes sem consultar esses rótulos. A aula compara o cálculo pela covariância, pela SVD e pelo scikit-learn.